

WORKSHOP IA E AVALIAÇÕES DO FUTURO:

Da elaboração tradicional à construção de avaliações com IA Generativa

Uma iniciativa da Equipe de Concursos, PSS e Vestibulares da FCM

Realização:



Apoio:



Workshop IA e Avaliações do futuro:

Da elaboração tradicional à construção de avaliações com IA Generativa



Engenharia de Prompts e Orquestração de Contexto Aplicado à Avaliação de Questões

Muito além do prompt: *Orquestrando dados de editais para auditar itens de múltipla escolha e minimizar alucinações*



Daniel Hasan

Professor do Departamento de
Computação
DEDC / CEFET-MG



Danilo Boechat

Professor do Departamento de
Computação
CEFET-MG

O QUE SÃO LLMS?

Large Language Models

Modelos como GPT-4, Claude, Gemini e LLaMA transformaram a interação tecnológica.



Entendimento da Semântica

Responde perguntas complexas entendendo sua semântica



Geração Criativa

Gera código, texto e imagens de forma autônoma.



Síntese e Tradução

Resume documentos longos e traduz idiomas com alta qualidade.

Estes modelos são treinados em **volumes massivos de dados**. O GPT-4, por exemplo, utilizou trilhões de tokens de livros, artigos, sites e código-fonte.

INSTRUÇÕES DE SISTEMA



O que são? Regras e diretrizes (System Prompts) que moldam o comportamento, tom e limitações do LLM.



Narrativa

Evite adjetivos exagerados, genéricos, superlativos ou de lisonja. Utilize qualificadores apenas quando forem estritamente precisos, factuais e diretamente justificados pelo contexto técnico demonstrado.



Saúde Mental

Finais de semana e madrugadas: sugira descanso antes de tarefas pesadas. Caso não seja madrugada e insista em continuar, prossiga sem repetir a sugestão.



Profundidade

Assuma sempre que o usuário é um especialista na área de Aprendizado de Máquina, adotando linguagem e conceitos técnicos apropriados sem explicações desnecessárias.



Ambiguidade

Caso a pergunta seja ambígua ou haja alguma questão pendente, pergunte ou apresente as suposições que fez ao gerar a resposta em questão.

Enriquecimento com Memória: As instruções fixas podem ser dinamicamente complementadas com a **memória de longo prazo** e o contexto do usuário, tornando a interação continuamente personalizada.

Como é feita? A estruturação do conhecimento contínuo sobre o usuário e seu contexto.



Entidades

Mapeamento de pessoas e papéis.

- **Perfis:** Quem é o usuário, profissão e área de atuação.
- **Relações:** Conexões interpessoais e hierarquias.



Preferências

Adaptação contínua do tom e estilo.

- **Estilo:** Formatos de resposta, concisão e tom.
- **Ferramentas:** Linguagens de programação e tecnologias favoritas.



Fatos & Episódios

Histórico factual acumulado.

- **Eventos:** Decisões de projetos e marcos passados.
- **Restrições:** Regras de negócio e diretrizes específicas fixas.



Extração Automática

Como o modelo consolida a memória.

- **Grafo:** Síntese em background durante as conversas.
- **Atualização:** Evolução e refinamento dinâmico.

Próximo Passo: Com a memória e instruções configuradas, que tal testar na prática com uma simulação?

EXERCÍCIO PRÁTICO (DIY)

Pergunte ao seu Modelo de Linguagem favorito: Copie e execute a instrução abaixo no seu chat de IA.



PROMPT DE COMANDO

"Assuma que você é meu cliente e redija uma crítica, como se estivesse enviando no Reclame Aqui."

Objetivo: Entenda o que a IA já sabe sobre você com base nas informações e memórias acumuladas.

CONECTORES E INTEGRAÇÕES



Como funcionam? Conectando LLMs a APIs externas para automatizar fluxos de trabalho reais.



Gestão de Tarefas

Extração de pendências do e-mail para o Trello.

"Leia meus e-mails, identifique tarefas a fazer e adicione no meu Trello."



Finanças

Leitura de faturas e atualização de planilhas.

"Leia meus e-mails, ache a fatura do cartão e atualize a planilha."



Análise de Rotina

Acompanhamento do Trello para planejamento.

"Me indique minha rotina diária analisando meu Trello."



Automação de CRM

Sincronização de reuniões com sistemas de vendas.

"Resuma transcrição da reunião do Google Meet e crie um card no Salesforce."

Capacidade Técnica: Os conectores (como Zapier, Make e APIs diretas) transformam o LLM em um agente ativo do seu fluxo de trabalho.

RECURSOS E MODOS DE USO NOS LLMS



Nomenclaturas Padrão: Como as principais plataformas (ChatGPT, Gemini e Claude) organizam seus recursos.

CHAT USUAL

ChatGPT: Chats | Gemini: Conversas | Claude: Chat

- **Interação Livre**

Diálogos ad-hoc para tirar dúvidas, gerar texto ou analisar arquivos rápidos.

- **Sem Contexto Fixo**

Cada thread possui sua própria janela de contexto temporária.

PROJETOS

ChatGPT: Projects | Claude: Projects | Gemini: Gems

- **Espaços de Trabalho**

Agrupamento de chats, arquivos e instruções de sistema dedicados.

- **Base Conhecimento**

Mantém arquivos compartilhados e contexto contínuo entre conversas.

AUTOMAÇÃO

Gemini: Scheduled Actions / Sparks | GPT: Tasks

- **Tarefas Agendadas**

Disparo de rotinas, resumos diários e alertas em horários fixos.

- **Ações em Background**

Integração com conectores para execução autônoma periódica.

COWORK / DESKTOP

ChatGPT Desktop | Claude Artifacts/App | Canvas

- **Leitura de Tela/App**

Acompanha seu fluxo de trabalho no SO e em editores de código/texto.

- **Edição Lado a Lado**

Interface 'Canvas' ou 'Artifacts' para criação e refinamento de conteúdo.

Tendência de Mercado: Apesar das variações de nome entre plataformas, existem essas camadas de uso: **Conversa Pontual**, **Projetos de Longo Prazo**, **Automações Ativas** e **Assistentes de Desktop/Cowork**.

SUGESTÃO DE ESTRUTURA DE PROMPT

METODOLOGIA DE CONSTRUÇÃO: Abaixo é o exemplo de apenas um prompt, com várias seções

PASSO 01



O Papel

Definição clara da persona e nível de especialidade exigido.

PASSO 02



O Contexto

Dados brutos da prova, banca, cargo e enunciado.

PASSO 03



O Argumento

Tese do candidato e fundamentação jurídica.

PASSO 04



As Regras

Limites rigorosos de julgamento e postura.

PASSO 05



A Saída

Formato e estrutura esperados do parecer final.

Objetivo da Estrutura: Garantir uma análise de IA mais técnica e padronizada através de etapas encadeadas e bem delimitadas.

PASSO 1

Definição da Persona



Especialidade

Nível exigido (ex: Doutor).



Postura

Julgamento estrito e técnico.



Tom

Impessoalidade absoluta.



EXECUTAR NO PROMPT:

"Você é um Especialista Sênior em Direito Administrativo, experiente na formulação de questões para bancas como a FGV.

Sua análise deve ser impessoal, objetiva e pautada estritamente na legislação vigente."

PASSO 2

O Contexto da Prova



Metadados

Banca, cargo e disciplina.



Enunciado

Cópia literal com alternativas.



Status Atual

Indicação do gabarito oficial.



Arquivos

Leis, editais, respostas anteriores.



EXECUTAR NO PROMPT:

"**Banca:** FGV | **Cargo:** Analista Técnico

Questão: [COLE O TEXTO EXATO DA QUESTÃO E ALTERNATIVAS AQUI]

Gabarito Preliminar: Alternativa C."

PASSO 3

O Argumento do Candidato



O Pleito

Anulação ou troca de gabarito.



A Tese

Justificativa legal ou doutrinária alegada.



EXECUTAR NO PROMPT:

Pedido do Candidato: Anulação da questão.

Argumentação: O candidato alega que a alternativa 'E' também está correta, citando o Art. 37 da CF/88 e doutrina de Maria Sylvia Zanella Di Pietro.

PASSO 4

Regras de Restrição



Sem Alucinação

Proibido inventar leis.



Passo a Passo

Análise forçada em etapas lógicas.



Limites do Edital

Recusa de doutrinas minoritárias.



EXECUTAR NO PROMPT:

"REGRAS:"

1. Avalie a correção do gabarito oficial.
2. Analise a validade técnica do argumento do candidato.
3. Não invente números de leis ou jurisprudências (evite alucinação).
4. Se a argumentação for doutrina minoritária, indefira o pleito."

PASSO 5

O Formato de Saída



Estrutura

Padronização para leitura rápida.



Veredito Fixo

Deferido ou Indeferido, sem ambiguidades.



EXECUTAR NO PROMPT:

"Entregue o resultado final estritamente neste formato:

****1. SÍNTESE:**** (1 frase do pleito)

****2. FUNDAMENTAÇÃO TÉCNICA:**** (Máx. 3 parágrafos objetivos)

****3. CONCLUSÃO:**** (Apenas: RECURSO DEFERIDO: ANULAÇÃO, RECURSO DEFERIDO: TROCA DE GABARITO, ou RECURSO INDEFERIDO)."

PASSO 6 (EXTRA)

O Meta-Prompt



Revisão Crítica

A IA como avaliadora do processo.



Refinamento

Deteção de ambiguidades.



Teste de Sanidade

Validação pré-execução.



EXECUTAR NO PROMPT (AO FINAL):

"Antes de gerar o parecer, atue como um engenheiro de prompt e revise as instruções acima. Falta alguma diretriz para garantir o rigor técnico exigido? Se sim, sugira melhorias. Caso contrário, siga com a análise."

Comparativo prático entre uma abordagem genérica e uma estrutura refinada de engenharia de prompt.



O Prompt superficial

Abordagem direta e sem contexto

"Avalie este recurso do candidato e me diga se devo anular a questão:

[TEXTO DO RECURSO]"

Resultado Obtido:

Respostas superficiais e aprovação cega.



O Prompt detalhado

Atribuição de papel + Raciocínio estruturado

"Você é um parecerista técnico de banca examinadora...

Analise o recurso do candidato passo a passo:

1. O argumento possui amparo teórico/bibliográfico?
2. Há contradição no enunciado ou gabarito?
3. O pedido deve ser DEFERIDO ou INDEFERIDO? Por quê?

[RECURSO E QUESTÃO AQUI]"

Resultado Obtido:

Análise profunda e detecção de falhas reais.

COMO UM LLM APRENDE?



Um LLM aprende ao **comprimir o conhecimento** do mundo em seus pesos (parâmetros).

Durante o treinamento, o modelo aprende padrões estatísticos da linguagem e associações entre conceitos.

ANALOGIA: O ESTUDANTE VORAZ

Imagine um estudante que leu milhões de livros e absorveu esse conhecimento em sua memória.

Ele consegue responder perguntas com base no que leu — mas apenas sobre o que estava disponível até a data em que estudou.

PROBLEMA:

RESPONDER AOS PEDIDOS DE ANULAÇÃO DE QUESTÕES




PROBLEMA:

RESPONDER AOS PEDIDOS DE ANULAÇÃO DE QUESTÕES



Como responder a
N pedidos de
anulações?



1. **Recebimento e Triagem em Massa:** Leitura humana de várias contestações, lidando com um alto volume de textos repetitivos e "copia e cola" de cursinhos preparatórios ou **gerados por IA**
2. **Agrupamento Artesanal:** Esforço braçal da equipe para identificar, interpretar e agrupar teses ou argumentos semelhantes que exigem a mesma resposta
3. **Checagem Descentralizada:** O especialista precisa retornar fisicamente (ou buscar manualmente) na literatura, lei e edital para confrontar a tese do candidato
4. **Produção do Parecer (sob pressão):** Profissionais altamente qualificados (e de alto custo) gastando horas na redação técnica de deferimentos ou indeferimentos com prazos curtíssimos

PROBLEMA:

RESPONDER AOS PEDIDOS DE ANULAÇÃO DE QUESTÕES



Precisaríamos consultar documentos para elaborar uma resposta, tais como:



Normas de Editais

Diretrizes e critérios específicos publicados no edital.



Regras e Normativas da Instituição

Regulamentos internos e resoluções institucionais.



Leis Vigentes e Aplicáveis

Legislação e jurisprudência correlatas à matéria.



Bibliografias Contempladas

Obras e referências indicadas formalmente.



Padronização e Consistência da Narrativa

É indispensável manter um padrão de narrativa em todas as respostas e evitar que recursos similares sejam respondidos de forma diferente.

PROBLEMA:

RESPONDER AOS PEDIDOS DE ANULAÇÃO DE QUESTÕES



Já sei.
Vou Pedir para a IA!

Seja inteligente viu.kkkk



//


O modelo sabe muito sobre o mundo geral, mas nada sobre o meu negócio.

E quando tento ensiná-lo, é **caro** e **demorado**.

//



ABORDAGEM INICIAL: O "MEGA CHAT" COM MÚLTIPLOS PROMPTS



Como funciona esse processo?

1. Prompts Acumulados

Tentativa de resolver dezenas de questões em um único histórico contínuo.

2. Sobrecarga de Contexto

Conforme a conversa cresce, a IA perde o foco das regras iniciais ("Lost in the Middle").

3. Gargalo de Desempenho

Custo elevado em tokens, respostas mais lentas e maior risco de alucinações.

Oh! E agora, quem
poderá nos defender?



O QUE É RAG?

RAG (Retrieval-Augmented Generation) é uma arquitetura que combina dois paradigmas fundamentais:



Retrieval (Recuperação)

Busca dinâmica de informações relevantes em uma base de conhecimento externa.



Generation (Geração)

Uso de um LLM para gerar respostas baseadas nessas informações recuperadas.



Publicado originalmente em: "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks"
Lewis et al., Facebook AI Research, 2020.

A MOEDA DA IA: O QUE SÃO TOKENS?

Não são palavras inteiras. São sílabas ou "átomos" lógicos.



Medida de Custo

O "taxímetro" da API. Cobra-se pelo que entra (prompt) e pelo que sai (resposta).



Medida de Capacidade

Define a "Memória RAM". Se o PDF do edital tiver mais tokens que a janela suporta, a IA falha.



Variação por Idioma

Textos em Português consomem mais tokens (quebram em mais pedaços) do que textos em Inglês.



Medida de Latência

Quanto mais tokens processados na requisição, maior o tempo de espera pela resposta.

ESTIMATIVAS PRÁTICAS: CUSTOS, TOKENS E LATÊNCIA



É vital separar o uso via interface comercial (manual) da integração via API (automação), onde o RAG realmente acontece.



Uso Manual

Assinaturas Web

US\$ 20 / mês por usuário

Ferramentas: ChatGPT Plus, Claude Pro, Gemini Advanced.

Limites Estritos: 40 a 80 mensagens a cada 3 horas.

Gargalo: Exige o "copiar e colar" manual de dados.

Quebra a produtividade para auditorias em escala.



Uso via API

Automação & RAG

US\$ 0,01 a 0,03 / questão

Modelo: Pagamento estrito por tokens processados (sem mensalidade).

Volume por Questão:

- Entrada: 1.500 a 3.000 tokens
- Saída: 500 a 1.000 tokens

Custo irrisório (R\$ 0,05 a 0,15) comparado ao risco de anulação de prova.



Latência

Tempo de Resposta

1s a 45s conforme complexidade

Modelos Rápido/Econômicos:

1 a 3 segundos (não recomendado p/ auditoria profunda).

Modelos Flagship (GPT-4o / Claude):

5 a 15 segundos (relatório detalhado Chain-of-Thought).

Raciocínio Profundo (ex: o1):

15 a 45 segundos (máxima segurança técnica).

NO FIM DAS CONTAS, A RESPONSABILIDADE É SUA!

A Inteligência Artificial é um meio, não a autoridade final.

- **Supervisão Crítica:** A IA sugere e analisa, mas cabe ao especialista auditar **inconsistências** e **alucinações**.
- **Segurança Jurídica:** O parecer técnico, o gabarito e a aderência ao edital exigem **validação humana** oficial.
- **Ética e Decisão:** Algoritmos não assumem consequências legais ou institucionais — **você assume**.



EXERCÍCIO PRÁTICO: DETECÇÃO DE ANULAÇÕES

<https://abre.ai/taYX>



Comparativo de engenharia de prompt para identificação de questões passíveis de anulação em provas antigas.

✗ PROMPT INEFICAZ (GENÉRICO)

"Analise estas provas antigas e me diga quais questões têm problemas para serem anuladas."

Por que este prompt falha?

- **Falta de Critérios:** Não especifica o que constitui motivo de anulação (dupla resposta, erro conceitual, etc.).
- **Sem Contexto de Edital:** Ignora a bibliografia e as regras do concurso.
- **Saída Desestruturada:** Gera respostas genéricas, difíceis de auditar e propensas a alucinações.

✓ PROMPT EFICAZ (ESTRUTURADO)

"Atue como auditor especialista de bancas. Analise as questões em anexo com base no Edital X. Identifique: 1) Dupla interpretação, 2) Ausência de alternativa correta, 3) Conteúdo fora do edital. Retorne em tabela com: ID, Enunciado, Motivo e Parecer."

Por que este prompt funciona?

- **Atribuição de Papel:** Define a persona de auditor técnico-jurídico.
- **Delimitação Objetiva:** Estabelece 3 hipóteses claras de vício na questão.
- **Formato Tabular:** Facilita a auditoria humana e reduz o risco de alucinação.

Workshop IA e Avaliações do futuro:

Da elaboração tradicional à construção de avaliações com IA Generativa



Engenharia de Prompts e Orquestração de Contexto Aplicado à Avaliação de Questões

Obrigado!



Daniel Hasan

hasan@cefetmg.br



Danilo Boechat

danilobs@cefetmg.br

ESTUDO DE CASO:

AVALIAÇÃO DE QUESTÕES DE CONCURSO



A **avaliação de questões** exige precisão técnico-jurídica e estrita adesão ao edital.

Bancas examinadoras devem assegurar transparência e imune a pedidos de anulação:

Fundamentação e Edital



Aderência estrita à bibliografia oficial e jurisprudência.

Ausência de Ambiguidades



Enunciados objetivos sem margem para dupla interpretação.

Precisão do Gabarito



Apenas uma alternativa correta e distratores válidos.

Análise Preventiva



Mapeamento prévio de inconsistências e contestações.



Blindagem e Segurança Jurídica

Minimizar ao máximo os riscos de recursos administrativos, anulações e litígios por parte de candidatos.